
1. Nhận audio hợp lệ
PCM16 WAV mono 16 kHz, 0,25–30 giây → tạo job
2. wav2vec2 ASR trên CPU
Sinh raw transcript và khoảng thời gian từ
3. wav2vec2 cascade-B + assessment trên CPU
Posterior + reference CMU → assessment → uncertain / gợi ý
4. Qwen base chuẩn hóa hình thức
Chỉ hội thoại tự do; lexical guard giữ nội dung đã nói
5. Qwen base sinh câu trả lời
Sampling hội thoại → lọc lặp / kiểm tra policy / retry tối đa 1
6. Công bố reply_ready
Câu trả lời cố định; UI/voice có thể bắt đầu trong khi feedback chờ
7. Grammar feedback cho hội thoại tự do
Hai lượt greedy: grammar_corrected rồi natural; guard từng trường
8. Kết thúc job
Luồng assessment mới bỏ qua legacy coach → ready / cancelled / error